

INSTITUCIÓN UNIVERSITARIA DE COLOMBIA

INGENIERÍA DE SISTEMAS

INGENIERÍA DE SOFTWARE II Y BIG DATA

**SESIÓN 3: ARQUITECTURA DEL PROYECTO,
COMPLEJIDAD ALGORÍTMICA Y LAS DIMENSIONES DEL BIG DATA**

**SANTIAGO HENAO JIMENEZ
KEVIN SMITH MONTENEGRO SANCHEZ
ALISSON NICOL PARRA LESMES
EDWARD ANDRES RUIZ AREVALO**

NOMBRE DE PROFE CHEVERE

21/08/2026

OCTAVO SEMESTRE

1. Definan los roles del equipo

NOMBRE	ROL	RESPONSABILIDAD
Santiago Henao	Arquitecto de Software	Diseñar la estructura y arquitectura del sistema.
Kevin Montenegro	QA / Documentación	Validar la calidad del sistema y documentar el proyecto.
Nicol Parra	Especialista en Visualización	Crear gráficos y reportes para el análisis de fraudes.
Edward Ruiz	Ingeniero ETL/Pandas	Preparar y transformar los datos para el análisis.

Presentación de Roles

- Yo soy Santiago Henao (Arquitecto de Software) y mi responsabilidad es Diseñar la estructura y arquitectura del sistema.
- Yo soy Kevin Montenegro (QA / Documentación) y mi responsabilidad es Validar la calidad del sistema y documentar el proyecto.
- Yo soy Nicol Parra (Especialista en Visualización) y mi responsabilidad es Crear gráficos y reportes para el análisis de fraudes.
- Yo soy Edward Ruiz (Ingeniero ETL/Pandas) y mi responsabilidad es Preparar y transformar los datos para el análisis.

2. El Arquitecto crea el repositorio en GitHub con el nombre sugerido y la estructura de carpetas.
3. Los demás integrantes clonan el repositorio y crean una rama de prueba (feature/mi-nombre).
4. Cada integrante hace un commit de prueba en su rama con un archivo de texto que diga su nombre y rol.
5. Todos hacen merge de su rama a develop y verifican que los cambios aparezcan en GitHub.
6. El QA/Documentación actualiza el README con los nombres de los integrantes y sus roles.

Default				
Branch	Updated	Check status	Behind Ahead	Pull request
main	yesterday		(Default)	...
Your branches				
Branch	Updated	Check status	Behind Ahead	Pull request
feature/Kevin	1 hour ago		0 1	...
Active branches				
Branch	Updated	Check status	Behind Ahead	Pull request
feature/santiago	16 minutes ago		0 1	...
feature/nic	33 minutes ago		0 1	...
Edward_Ruiz	1 hour ago		0 2	...
feature/Kevin	1 hour ago		0 1	...

LINK DATASET

<https://www.kaggle.com/datasets/waqasishtiaq/credit-card-fraud-dataset>

Formulación del Problema: Lista de 3 hipótesis o preguntas de negocio críticas que el software analítico deberá resolver automáticamente mediante código

H1 – ¿El monto de la transacción (Amount) es un factor discriminante para identificar fraude?

Pregunta de negocio: ¿Los fraudes tienden a ocurrir en montos significativamente distintos (más bajos o más altos) que las transacciones legítimas? Validación por código: comparar estadísticos descriptivos de Amount agrupados por Class (media, mediana, percentiles) y aplicar una prueba estadística (ej. Mann-Whitney U, dado que Amount no sigue distribución normal) para determinar si la diferencia es significativa.

H2 – ¿El momento de la transacción (Time) influye en la probabilidad de fraude?

Pregunta de negocio: ¿Existen franjas horarias (dentro de las ~48 horas que cubre el dataset) donde se concentra un mayor porcentaje de fraudes, sugiriendo patrones temporales explotables por los defraudadores (ej. madrugada, baja vigilancia)? Validación por código: discretizar Time en bloques horarios, calcular la tasa de fraude (Class=1) por bloque y visualizar/comparar contra la tasa base de 0.17%.

H3 – ¿Es posible construir un modelo que detecte fraude con un Recall aceptable a pesar del extremo desbalance de clases (99.83% vs 0.17%)?

Pregunta de negocio: ¿El desbalance de clases impide obtener un modelo útil en producción, o mediante técnicas de balanceo (SMOTE/undersampling) se puede lograr un Recall mínimo objetivo (ej. ≥ 0.85) sin disparar excesivamente los falsos positivos (Precisión)?

Validación por código: entrenar al menos dos versiones del modelo (con y sin balanceo) y comparar Recall, Precision, F1 y AUC-PR sobre el conjunto de prueba estratificado.